

XAI Project

Heart Failure Clinical Records

Confronto tra modelli interpretabili basati su regole
e modelli ensemble non interpretabili

Mattia Manneschi

Laboratorio di Explainable AI

Contents

1	Introduzione del problema e dataset	2
1.1	Contesto e motivazione	2
1.2	Il Dataset	3
1.3	EDA — Distribuzioni per classe	4
1.4	EDA — Matrice di correlazione	6
2	Architettura e Implementazione	6
2.1	Struttura del Progetto	6
2.2	Pipeline di Elaborazione dei Dati	8
2.3	Modelli Interpretabili Basati su Regole	9
2.4	Modelli Ensemble Non Interpretabili	10
2.5	Configurazione e Iperparametri	11
2.6	Analisi delle performance in funzione degli iperparametri	12
3	Risultati	13
3.1	Metriche Comparative	13
3.2	Curve ROC	15
3.3	Matrici di Confusione	17
3.4	Regole Complete: tutti i modelli interpretabili	19
3.5	Cross-Validation 10-fold	23
3.6	RF e GRL senza feature <code>time</code>	24
3.7	Interpretabilità	25
4	Conclusioni	27
4.1	Confronto, analisi clinica e limiti	27

1 Introduzione del problema e dataset

1.1 Contesto e motivazione

Il problema. L'insufficienza cardiaca è una condizione clinica grave in cui il cuore non riesce a pompare sangue in modo sufficiente. Identificare i fattori di rischio associati al decesso è fondamentale per supportare le decisioni cliniche e migliorare la prognosi dei pazienti.

Obiettivo. Il progetto confronta due famiglie di modelli di machine learning per la predizione della mortalità: modelli interpretabili basati su regole (rule-based) e modelli non interpretabili basati su ensemble di alberi. L'obiettivo è valutare il trade-off tra performance predittiva e interpretabilità in un contesto clinico ad alta criticità.

Explainable AI in ambito clinico. In medicina, un modello non spiegabile — per quanto accurato — non è direttamente utilizzabile come strumento di supporto decisionale: il medico deve poter comprendere e validare le motivazioni di ogni predizione. I modelli intrinsecamente interpretabili soddisfano questo requisito senza richiedere metodi post-hoc aggiuntivi (es. SHAP, LIME), che possono introdurre approssimazioni e spiegazioni fuorvianti.

Struttura del report. Il Capitolo 1 introduce il problema clinico, descrive il dataset e presenta l'analisi esplorativa. Il Capitolo 2 illustra l'architettura del progetto, la pipeline di elaborazione dei dati, i modelli utilizzati e la loro configurazione. Il Capitolo 3 presenta i risultati e il confronto delle performance. Il Capitolo 4 raccoglie le conclusioni, l'analisi clinica dei risultati e i limiti del lavoro.

1.2 Il Dataset


Il dataset *Heart Failure Clinical Records* (UCI, id=519) raccoglie cartelle cliniche di 299 pazienti con insufficienza cardiaca seguiti in follow-up. La variabile target **DEATH_EVENT** indica se il paziente è deceduto durante il periodo di osservazione.

Campioni: 299 | Decessi: 96 (32.1%) | Sopravvissuti: 203 (67.9%)

Gestione delle feature: binarie vs continue. Le 12 feature si dividono in 5 binarie (**anaemia**, **diabetes**, **high_blood_pressure**, **sex**, **smoking**) e 7 continue. I modelli ensemble e la maggior parte dei rule-based le ricevono direttamente. RuleFit richiede standardizzazione (StandardScaler), mentre BayesianRuleList richiede feature esclusivamente binarie: le variabili continue vengono discretizzate in bin tramite KBinsDiscretizer (one-hot, 4 bin quantili) prima del fitting.


Feature	Tipo	Descrizione
age	continua	Eta' del paziente (anni)
anaemia	binaria	Presenza di anemia (0/1)
creatinine_phosphokinase	continua	Livello CPK nel sangue (mcg/L)
diabetes	binaria	Presenza di diabete (0/1)
ejection_fraction	continua	Percentuale di sangue pompata dal ventricolo sinistro (%)
high_blood_pressure	binaria	Presenza di ipertensione (0/1)
platelets	continua	Conta piastrinica (kiloplatelets/mL)
serum_creatinine	continua	Livello di creatinina serica (mg/dL)
serum_sodium	continua	Livello di sodio sierico (mEq/L)
sex	binaria	Sesso biologico (0=F, 1=M)
smoking	binaria	Fumatore (0/1)
time	continua	Durata del follow-up (giorni)

1.3 EDA — Distribuzioni per classe



Ogni istogramma sovrappone la distribuzione di una feature per sopravvissuti (blu) e deceduti (rosso). `time` è il discriminatore più potente: un follow-up breve corrisponde quasi sempre a decesso. `serum_creatinine` alta indica compromissione renale; `ejection_fraction` bassa segnala ridotta capacità di pompa. `platelets` e `creatinine_phosphokinase` mostrano distribuzioni largamente sovrapposte.

1.4 EDA — Matrice di correlazione



`time` ha la correlazione più forte con `DEATH_EVENT` (-0.53): pazienti con follow-up lungo tendono a sopravvivere. `serum_creatinine` ($+0.29$) ed `ejection_fraction` (-0.27) sono i segnali biochimici più informativi. Le feature binarie mostrano correlazioni deboli ($< \pm 0.15$).

2 Architettura e Implementazione

2.1 Struttura del Progetto

Il progetto è organizzato in una cartella `src/` con sette moduli distinti, ciascuno con una responsabilità precisa. Questa separazione permette di modificare una componente senza toccare le altre e rende il codice più leggibile e testabile.

Modulo	Responsabilita'
config.py	Centralizza iperparametri, path e costanti
data__loader.py	Download UCI, cache CSV, split stratificato 60/20/20, tre varianti di preprocessing
models.py	Factory function per ciascuno dei 9 modelli; accetta **params per override
evaluate.py	Calcolo metriche, generazione di tutti i grafici, cross-validation
tune.py	Grid search esaustiva sul validation set (ROC-AUC)
main.py	Orchestrazione dell'intera pipeline end-to-end
report__latex.py	Legge gli artefatti salvati e genera il report LaTeX/PDF

Output della pipeline. Ogni esecuzione di `main.py` produce artefatti su disco: i dati grezzi vengono cachati in `data/`; le metriche e le regole vengono salvate in `results/files/`; i grafici in `results/plots/`; il report finale in `Report/`.

Dipendenze principali. `scikit-learn` gestisce preprocessing, metriche e cross-validation. `imodels` fornisce le implementazioni dei modelli rule-based (RuleFit, GreedyRuleList, BayesianRuleList, FIGS, SkopeRules). `wittgenstein` implementa RIPPER. `xgboost` implementa XGBoost. `ucimlrepo` scarica il dataset direttamente dal repository UCI.

2.2 Pipeline di Elaborazione dei Dati

Split stratificato 60/20/20. Il dataset viene diviso in tre parti con doppio `train_test_split` stratificato: training (≈ 179 campioni, 60%), validation (≈ 60 campioni, 20%) e test (≈ 60 campioni, 20%). La stratificazione garantisce che ogni partizione mantenga la stessa proporzione di deceduti ($\sim 32\%$) presente nel dataset originale. Il validation set viene usato esclusivamente per la selezione degli iperparametri; il test set è mantenuto completamente separato e usato una sola volta per la valutazione finale.

Tre varianti di preprocessing. I modelli richiedono rappresentazioni diverse: (1) *raw* — il DataFrame originale con le 12 feature, usato da GreedyRuleList, FIGS, SkopeRules, RIPPER e dagli ensemble; (2) *scalata* — StandardScaler porta le feature continue a media 0 e varianza 1, necessaria per RuleFit che usa Lasso internamente; (3) *discretizzata* — KBinsDiscretizer (4 bin quantili, one-hot) produce ≈ 33 colonne binarie, obbligatoria per BayesianRuleList.

PreparedData — struttura dati condivisa. Il preprocessing è incapsulato in un data-class PreparedData con i campi: `X_train/X_val/X_test` (raw), le varianti scalate e discretizzate per ciascuna partizione, `X_trainval/y_trainval` (train+val, usato per la cross-validation), `y_train/y_val/y_test` e `scale_pos_weight` per XGBoost. Scaler e discretizzatore sono fittati solo sul training set e applicati con `transform()` a validation e test, evitando data leakage.

Sbilanciamento delle classi. Il dataset contiene 203 sopravvissuti e 96 deceduti ($\sim 32\%$ positivi). Random Forest usa `class_weight='balanced'`; XGBoost usa `scale_pos_weight` calcolato come rapporto negativi/positivi nel training set.

2.3 Modelli Interpretabili Basati su Regole

I modelli basati su regole producono predizioni if-then direttamente leggibili da un esperto di dominio, senza richiedere strumenti post-hoc aggiuntivi.

RuleFit. Estrae regole da un ensemble di alberi e le pondera con regressione Lasso. Il coefficiente di ogni regola indica il suo contributo alla predizione; richiede feature standardizzate.

GreedyRuleList (GRL). Costruisce una lista ordinata di regole if-then in modo greedy. Ogni regola è un decision stump (una condizione su una feature); il parametro `max_depth` controlla la lunghezza della lista. Si applica la prima regola soddisfatta; se nessuna si attiva, vale la regola di default. Importante: GRL produce sempre regole a condizione singola per design della libreria `imodels`.

BayesianRuleList (BRL). Apprende una lista di regole tramite MCMC su feature binarie. Le variabili continue vengono discretizzate in bin prima del fitting; produce stime probabilistiche con IC al 95%. Il parametro `maxcardinality` controlla il numero massimo di condizioni per regola; dal tuning sul validation set è risultato ottimale il valore 1.

FIGS — Fast Interpretable Greedy-Tree Sums. Somma di piccoli alberi decisionali, ciascuno appreso greedy sui residui del precedente. La predizione è la somma dei valori “Val” raggiunti traversando ogni albero; per i classificatori viene poi applicata una softmax. Struttura additiva trasparente con capacità espressiva maggiore di un singolo albero.

SkopeRules. Genera regole ad alta precisione tramite sub-campionamenti ripetuti di ensemble di alberi, poi de-duplica quelle simili. La profondità degli alberi base (`max_depth`) controlla il numero di condizioni AND per regola; ogni regola è corredata da precisione e recall.

RIPPER — Repeated Incremental Pruning to Produce Error Reduction. Apprende regole congiuntive (AND tra più condizioni simultanee) in modo incrementale, potando ogni regola per ridurre l'errore. La prima regola soddisfatta predice Decesso; se nessuna si attiva, la predizione è Sopravvissuto (DEFAULT). A differenza di GRL, può combinare più feature in un singolo antecedente.

2.4 Modelli Ensemble Non Interpretabili

I modelli ensemble combinano centinaia di alberi decisionali per ottenere performance superiori, ma il processo decisionale risulta opaco (black box). Sono usati come baseline di riferimento per valutare il gap di performance rispetto ai modelli interpretabili.

Random Forest. Allena N alberi su sotto-campioni casuali del dataset (bagging) e su sottoinsiemi casuali delle feature (feature bagging). La predizione finale è la media delle probabilità dei singoli alberi. Configurato con `class_weight='balanced'`.

Gradient Boosting (sklearn). Allena alberi sequenzialmente: ogni albero corregge gli errori del precedente minimizzando il gradiente della loss. Riduce il bias rispetto al bagging.

XGBoost. Implementazione ottimizzata del gradient boosting con regolarizzazione L1/L2, gestione nativa dei valori mancanti e parallelismo. Usa `scale_pos_weight` per bilanciare le classi.

2.5 Configurazione e Iperparametri

Il dataset (299 campioni) è suddiviso in tre parti stratificate: train 60%, validation 20%, test 20% ($\approx 179/60/60$ campioni). Gli iperparametri di GreedyRuleList, BayesianRuleList, SkopeRules e dei tre ensemble vengono scelti massimizzando il ROC-AUC sul validation set tramite grid search esaustiva. RuleFit, FIGS e RIPPER usano i parametri di default della libreria. La valutazione finale avviene sul test set, mantenuto separato durante tutto il processo di selezione.

Grid di ricerca — migliori valori sul validation set

Modello	Parametro	Valori esplorati	Ottimo (val)
GreedyRuleList	max_depth	1, 2, 3, 4, 6	2
BayesianRuleList	maxcardinality	1, 2, 3	1
SkopeRules	max_depth	2, 3, 4	2
SkopeRules	precision_min	0.4, 0.5	0.4
SkopeRules	recall_min	0.2, 0.3	0.2
RandomForest	n_estimators	100, 200	100
RandomForest	max_depth	None, 5, 10	—
RandomForest	min_samples_leaf	1, 2, 5	5
GradientBoosting	n_estimators	100, 200	100
GradientBoosting	learning_rate	0.05, 0.1	0.1
GradientBoosting	max_depth	3, 4, 5	3
XGBoost	n_estimators	100, 200	100
XGBoost	learning_rate	0.05, 0.1	0.05
XGBoost	max_depth	3, 4, 5	4


Parametri fissi (non ottimizzati)

Parametro	Valore	Motivazione
RANDOM_STATE	42	Seed fisso per riproducibilità
TEST_SIZE	0.20	20% test (≈ 60 campioni), mantenuto separato durante il tuning
VAL_SIZE	0.20	20% validation (≈ 60 campioni) per la scelta degli iperparametri
CV_FOLDS	10	10-fold CV su trainval (≈ 240 campioni): stima robusta della stabilità
BRL_MAX_ITER	20,000	Iterazioni MCMC per la convergenza (ridotto a 3,000 durante il tuning)
RULEFIT_MAX_RULE	30	Limita le regole candidate; troppe degenerano in black-box
FIGS_MAX_RULES	10	Alberi nella somma FIGS; oltre 10 si perde interpretabilità


2.6 Analisi delle performance in funzione degli iperparametri

Per ciascun modello ottimizzato è riportato il ROC-AUC sul validation set al variare di ogni iperparametro (marginalizzando sugli altri: per ogni valore del parametro si considera il massimo AUC tra tutte le combinazioni che lo includono). Le barre evidenziaste corrispondono al valore ottimale selezionato.

Modelli rule-based. Per GreedyRuleList `max_depth=2` è il punto di equilibrio: liste troppo corte (`max_depth=1`) non catturano abbastanza pattern; liste lunghe (`max_depth=3`) non portano benefici su questo dataset. Per BayesianRuleList la cardinalità ottimale è 1: regole a condizione singola sono sufficienti per separare le classi, e aumentare `maxcardinality` non migliora il ROC-AUC sul validation set. Per SkopeRules, `max_depth=2` genera regole bi-condizionali ad alta precisione; profondità maggiori producono overfitting. Abbassare `precision_min` e `recall_min` allarga il set di regole candidate, migliorando la copertura.




Modelli ensemble. Tutti e tre i modelli mostrano scarsa sensibilità al numero di stimatori nell'intervallo [100, 200]: la performance è già stabile a 100. Per Random Forest `max_depth=None` (alberi completi) domina; `min_samples_leaf=5` riduce la varianza su dataset piccoli. Gradient Boosting e XGBoost preferiscono alberi poco profondi (`max_depth=3-4`), coerente con la dimensione ridotta del dataset.



3 Risultati


3.1 Metriche Comparative

Modello	Tipo	Accuracy	Precision	Recall	F1	ROC-AUC
SkopeRules	Rule-based	0.7000	1.0000	0.0526	0.1000	0.8960
RandomForest	Ensemble	0.8667	0.9231	0.6316	0.7500	0.8960
XGBoost	Ensemble	0.8667	0.8667	0.6842	0.7647	0.8434
RuleFit	Rule-based	0.8000	0.7692	0.5263	0.6250	0.8370
GradientBoosting	Ensemble	0.7500	0.6429	0.4737	0.5455	0.8344
GreedyRuleList	Rule-based	0.8333	0.9091	0.5263	0.6667	0.8331
FIGS	Rule-based	0.8000	0.7692	0.5263	0.6250	0.7677
BayesianRuleList	Rule-based	0.8000	0.7692	0.5263	0.6250	0.7651
RIPPER	Rule-based	0.7333	0.7143	0.2632	0.3846	0.6123




Accuracy e F1 riassumono la qualità complessiva, ma su classi sbilanciate possono essere fuorvianti. Precision misura quante predizioni “deceduto” sono corrette; Recall quante morti reali vengono identificate — in clinica un Recall basso è più pericoloso di una Precision bassa. ROC-AUC è la metrica più robusta: misura la capacità di separare le classi indipendentemente dalla soglia. GreedyRuleList raggiunge buon F1 e Accuracy con regole a condizione singola. SkopeRules ottiene Precision=1.0 con Recall molto basso: identifica pochi deceduti ma senza mai sbagliare. RIPPER produce regole congiuntive (AND) ma ha il ROC-AUC più basso tra tutti i modelli, dimostrando che la complessità strutturale non implica migliore capacità discriminativa.

3.2 Curve ROC



La curva ROC traccia il TPR (Recall) contro il FPR al variare della soglia; l'AUC riassume la performance in un unico numero indipendente dalla soglia (0.50 = casuale, 1.0 = perfetto). Random Forest raggiunge l'AUC più alto tra tutti i modelli. SkopeRules e GreedyRuleList mostrano risultati notevoli per modelli intrinsecamente interpretabili. RIPPER ha l'AUC più basso: nonostante F1 e Accuracy competitivi, il ranking probabilistico è meno calibrato.

3.3 Matrici di Confusione



Ogni cella indica: riga = classe reale, colonna = classe predetta. La diagonale raccoglie le predizioni corrette; gli elementi fuori diagonale sono gli errori. In clinica i due tipi di errore hanno costo asimmetrico: un falso negativo (morte non rilevata) è più grave di un falso positivo (falso allarme). BayesianRuleList massimizza il Recall sui deceduti — pochi falsi negativi — a scapito di più falsi positivi. Gli ensemble bilanciano meglio i due errori. SkopeRules ha Precision=1.0 ma Recall molto basso: identifica pochi deceduti, senza mai produrre falsi positivi.

3.4 Regole Complete: tutti i modelli interpretabili

GreedyRuleList. Lista IF/THEN sequenziale: la prima regola soddisfatta determina la classe, che non è necessariamente Decesso — ogni regola predice la classe di maggioranza del proprio segmento ($>50\%$ deceduti $\Rightarrow$ Decesso). GRL è strutturalmente limitato a una condizione per regola; il parametro `max_depth` controlla la lunghezza della lista.

Condizione	Precisione	Recall	Predizione	Campioni
time ≤ 73.500	0.830	0.672	Decesso	47
serum_creatinine > 1.450	0.500	0.091	Sopravvissuto	22
DEFAULT	0.927	0.843	Sopravvissuto	110

BayesianRuleList. Lista IF/ELSE con MCMC su feature discretizzate. Ogni antecedente ha al massimo `maxcardinality` condizioni congiuntive; il valore ottimale (1) è stato scelto sul validation set. $P(\text{decesso})$ è la probabilità posteriore con IC al 95%.

Condizione	P(decesso)	IC 95\%
serum_creatinine $\in (0.50, 0.90]$	6.1%	0.8%–16.2%
time $\in (6.00, 71.50]$	84.4%	72.6%–93.4%
ejection_fraction $\in (15.00, 30.00]$	51.9%	33.4%–70.1%
DEFAULT (nessuna regola attivata)	9.8%	4.4%–17.0%

RIPPER. Ogni regola ha un antecedente con più condizioni AND (tutte devono essere verificate simultaneamente). Se tutte le condizioni di una regola sono soddisfatte $\Rightarrow$ Decesso; nessuna regola soddisfatta $\Rightarrow$ Sopravvissuto (DEFAULT).

Regola	Predizione	Precisione	Recall	Campioni
time ≤ 28.8	Decesso	1.000	0.310	18
ejection_fraction ≤ 25.0 AND high_blood_pressure = 1	Decesso	0.769	0.172	13
ejection_fraction ≤ 25.0 AND platelets $\in (197200.0, 220400.0]$	Decesso	1.000	0.069	4
time $\in (28.8, 57.4]$ AND sex = 0	Decesso	0.875	0.121	8
DEFAULT	Sopravvissuto	0.860	0.967	136

RuleFit — regole con coefficiente positivo (pro Decesso). Ogni regola è un percorso estratto da un ensemble di alberi; il coefficiente Lasso indica il peso nella predizione finale. Valori più alti indicano maggiore contributo al rischio di decesso. Le regole possono combinare più feature (AND implicito sul percorso).

Regola	Coefficiente
time <= 0.67896 and time > 0.23773	3.147
time <= -0.62527 and serum_creatinine > -0.44392	1.342
time > -0.69016 and creatinine_phosphokinase <= -0.01926 and creatinine_phosphokinase > -0.33791 and serum_creatinine > -0.14962	1.263
time <= 0.67896	1.130
time > -0.67718 and creatinine_phosphokinase > 0.25316 and ejection_fraction <= -0.41598 and serum_creatinine > -0.50523	1.006
time > -0.68367 and creatinine_phosphokinase <= -0.01926 and creatinine_phosphokinase > -0.49123 and serum_creatinine > 0.16921	0.877
time <= -0.67718 and serum_creatinine <= 0.35315 and serum_creatinine > -0.56654	0.704
time <= -1.02108 and creatinine_phosphokinase <= 1.22865	0.622

SkopeRules. Regole ad alta precisione estratte tramite sub-campionamenti di ensemble di alberi, poi de-duplicate. La profondità degli alberi base (**max_depth** ottimizzato sul validation set) controlla il numero di condizioni per regola. Ogni regola è corredata da Precisione e Recall sul training set.

Regola	Precisione	Recall
time <= 78.5 and serum_creatinine > 0.85	0.837	0.707
time <= 78.5 and serum_creatinine > 0.75	0.820	0.707
time <= 73.5 and serum_creatinine > 0.75	0.848	0.672
time <= 67.5 and serum_creatinine > 0.75	0.881	0.638
time <= 73.5 and serum_creatinine > 0.85	0.867	0.672
time <= 78.5 and ejection_fraction > 27.5	0.703	0.448
time <= 73.5 and serum_creatinine > 0.95	0.878	0.621
time <= 67.5 and creatinine_phosphokinase <= 142.0	0.800	0.207
time <= 69.0 and high_blood_pressure <= 0.5	0.727	0.276
time <= 67.5	0.860	0.638
ejection_fraction <= 32.5 and serum_creatinine <= 1.815	0.521	0.431
time <= 66.5 and serum_creatinine > 0.75	0.878	0.621
age <= 61.0 and time <= 78.0	0.720	0.310
ejection_fraction > 22.5 and serum_creatinine > 1.45	0.606	0.345
time <= 67.5 and time > 28.5	0.760	0.328
time <= 52.0	0.909	0.517
time <= 78.5 and time > 28.5	0.676	0.397
serum_creatinine > 1.45 and serum_sodium > 130.5	0.706	0.414
time <= 73.5 and high_blood_pressure <= 0.5	0.720	0.310
creatinine_phosphokinase > 89.5 and serum_creatinine > 1.45	0.759	0.379
time > 73.5 and ejection_fraction <= 32.5	0.366	0.259
time <= 73.5 and high_blood_pressure > 0.5	0.955	0.362
ejection_fraction > 27.5 and serum_creatinine > 1.45	0.667	0.276
time <= 55.0	0.861	0.534
time <= 73.5 and time > 28.5	0.724	0.362
time <= 67.5 and creatinine_phosphokinase > 142.0	0.893	0.431
time <= 73.5 and serum_sodium <= 136.5	0.960	0.414
time <= 28.5	1.000	0.310
time <= 73.5 and serum_sodium > 136.5	0.682	0.259
time <= 73.5 and platelets > 124500.0	0.844	0.655


Regola	Precisione	Recall
ejection_fraction <= 27.5 and serum_creatinine > 0.85	0.676	0.431
creatinine_phosphokinase > 71.0 and ejection_fraction <= 27.5	0.676	0.431
time <= 73.5 and time > 28.0	0.724	0.362
ejection_fraction <= 27.5 and serum_creatinine <= 1.45	0.615	0.276
creatinine_phosphokinase > 75.5 and serum_creatinine > 1.45	0.767	0.397
time <= 67.5 and time > 28.0	0.760	0.328
time > 52.0 and serum_creatinine <= 1.45	0.124	0.259
time > 67.5 and ejection_fraction <= 27.5	0.464	0.224
time <= 28.0	1.000	0.310
time <= 66.5 and time > 28.5	0.750	0.310
time > 66.5 and ejection_fraction <= 32.5	0.395	0.293
ejection_fraction > 27.5 and serum_creatinine > 1.815	0.786	0.190
time <= 78.5 and time > 55.0	0.625	0.172
time <= 78.0 and time > 28.5	0.676	0.397
ejection_fraction <= 32.5 and serum_creatinine > 0.95	0.646	0.534
time > 73.5 and serum_creatinine > 1.55	0.500	0.172
creatinine_phosphokinase > 59.5 and serum_creatinine > 1.45	0.727	0.414
ejection_fraction <= 27.5 and platelets <= 195000.0	0.375	0.052
time <= 69.0 and high_blood_pressure > 0.5	0.955	0.362
time > 73.5 and serum_creatinine > 1.45	0.500	0.190
time <= 67.5 and serum_sodium > 136.5	0.750	0.259
time <= 67.5 and serum_sodium <= 136.5	0.957	0.379
ejection_fraction <= 22.5	0.917	0.190
creatinine_phosphokinase > 69.0 and serum_creatinine > 1.45	0.742	0.397
ejection_fraction <= 27.5 and platelets > 195000.0	0.688	0.379
ejection_fraction <= 27.5 and ejection_fraction > 22.5	0.500	0.241
time > 73.5 and ejection_fraction <= 27.5	0.444	0.207
ejection_fraction > 27.5 and serum_sodium <= 134.5	0.412	0.241
platelets <= 319000.0 and serum_creatinine > 1.45	0.594	0.328
time > 78.5 and ejection_fraction <= 22.5	0.800	0.069
time > 66.5 and ejection_fraction <= 27.5	0.483	0.241
ejection_fraction > 27.5 and serum_creatinine > 1.85	0.750	0.155
time > 52.0 and serum_creatinine > 1.45	0.520	0.224
age > 61.0 and time <= 78.0	0.852	0.397

FIGS — Fast Interpretable Greedy-Tree Sums. FIGS è una somma di alberi: ogni albero assegna al campione un valore numerico e se la somma supera 0.5 la predizione è Decesso. Di seguito la struttura completa degli alberi appresi:

```
> -----
> FIGS-Fast Interpretable Greedy-Tree Sums:
> Predictions are made by summing the "Val" reached by traversing each tree.
> For classifiers, a softmax function is then applied to the sum.
> -----
time <= 73.500 (Tree #0 root)
  time <= 52.000 (split)
    Val: 0.077 0.923 (leaf)
    serum_sodium <= 137.000 (split)
      Val: 0.163 0.837 (leaf)
      ejection_fraction <= 30.000 (split)
        Val: 0.258 0.742 (leaf)
        Val: 0.926 0.074 (leaf)
      serum_creatinine <= 1.450 (split)
        Val: 0.898 0.102 (leaf)
        creatinine_phosphokinase <= 69.000 (split)
          Val: 1.059 -0.059 (leaf)
          time <= 104.000 (split)
            Val: 0.125 0.875 (leaf)
            serum_creatinine <= 1.965 (split)
              Val: 0.492 0.508 (leaf)
              Val: 1.258 -0.258 (leaf)

+
ejection_fraction <= 27.500 (Tree #1 root)
  time <= 148.000 (split)
    Val: -0.104 0.104 (leaf)
    Val: -0.36 0.36 (leaf)
  Val: 0.074 -0.074 (leaf)
```

3.5 Cross-Validation 10-fold



Il boxplot mostra la distribuzione del ROC-AUC su 10 fold stratificati del set trainval (≈ 240 campioni): mediana, IQR (bordi del box) e range (baffi). La stratificazione garantisce che ogni fold mantenga la stessa proporzione di deceduti ($\sim 32\%$). I modelli usano gli iperparametri ottimizzati sul validation set. Random Forest ha la mediana più alta e IQR contenuto: performance stabile e consistente. RuleFit è il miglior rule-based in CV. FIGS mostra alta varianza — instabile su dataset piccoli. GreedyRuleList usa un custom scorer che aggira un'incompatibilità con l'API sklearn.

3.6 RF e GRL senza feature time

Motivazione. La feature `time` (durata del follow-up) è la più predittiva del dataset. In contesti reali di triage questa informazione non è sempre disponibile al momento della prima valutazione. Questo esperimento valuta RF e GRL privandoli di `time`, forzandoli ad appoggiarsi ai segnali biochimici e demografici rimanenti. RF e GRL vengono ri-tunati sul proprio validation set (senza `time`) per garantire un confronto equo.

Modello	Accuracy	F1	ROC-AUC
RandomForest	0.8667	0.7500	0.8960
RF_no_time	0.7500	0.5161	0.7754
GreedyRuleList	0.8333	0.6667	0.8331
GRL_no_time	0.6833	0.5366	0.7003


Rimuovendo `time`, il ROC-AUC scende di circa 0.10 per entrambi i modelli: un costo atteso dato il peso dominante di `time`. Senza di essa i modelli si affidano a `serum_creatinine` ed `ejection_fraction` — feature biochimiche disponibili alla prima valutazione, prima del follow-up — e rimangono utilizzabili in contesti di triage.

Regole GRL senza time. Con la rimozione di `time`, GreedyRuleList apprende dai segnali biochimici: `serum_creatinine` ed `ejection_fraction` diventano le feature dominanti.

Condizione	Precisione	Recall	Predizione	Campioni
<code>serum_creatinine > 1.450</code>	0.658	0.431	Decesso	38
<code>ejection_fraction <= 27.500</code>	0.615	0.276	Decesso	26
<code>creatinine_phosphokinase > 5211.000</code>	1.000	0.034	Decesso	2
<code>age > 81.500</code>	0.500	0.025	Sopravvissuto	6
<code>diabetes > 0.500</code>	0.816	0.331	Sopravvissuto	49
<code>serum_creatinine <= 0.650</code>	0.667	0.017	Sopravvissuto	3
DEFAULT	0.964	0.438	Sopravvissuto	55


3.7 Interpretabilità

Regole RuleFit — coefficienti Lasso.



Coefficienti Lasso delle regole estratte da RuleFit: positivo (barre rosse) $\Rightarrow$ la regola aumenta il rischio di decesso; negativo (blu) $\Rightarrow$ lo riduce. Le regole pro-decesso con peso più alto coinvolgono **time** basso e **serum_creatinine** alta. Le regole pro-sopravvivenza implicano **ejection_fraction** più alta e follow-up lungo. La penalizzazione Lasso azzerava i coefficienti ridondanti, mantenendo solo le regole con effetto reale sulla predizione.

Feature Importance — Random Forest (MDI).



L'importanza MDI misura di quanto ogni feature riduce l'impurità media nei 200 alberi del Random Forest: **time** domina nettamente, seguita da **serum_creatinine** ed **ejection_fraction**. Questa gerarchia è confermata in modo indipendente da RuleFit (sezione 3.4): le regole con coefficiente Lasso più alto coinvolgono **time** basso e **serum_creatinine** alta. Due metodi radicalmente diversi —

importance da ensemble di alberi vs regressione Lasso su regole estratte — convergono sugli stessi tre segnali fisiopatologici, coerenti con la letteratura sull'insufficienza cardiaca.

4 Conclusioni

4.1 Confronto, analisi clinica e limiti

Confronto tra approcci. I modelli ensemble raggiungono ROC-AUC superiore (Random Forest 0.896, XGBoost 0.843) ma il divario con i rule-based non è netto: GreedyRuleList (0.833) è competitivo su un dataset di soli 299 campioni, dove la semplicità strutturale riduce il rischio di overfitting. GreedyRuleList offre il miglior F1 rule-based (0.667) con una lista ordinata di condizioni leggibile da un clinico. RuleFit assegna coefficienti espliciti a ogni regola, rendendo visibile il peso relativo di ciascuna. BayesianRuleList privilegia il recall (0.526): sovrastima i decessi, il che in medicina è spesso preferibile a sottostimarli. FIGS ha struttura additiva particolarmente trasparente. SkopeRules raggiunge Precision=1.0 con Recall molto basso: non produce mai falsi positivi, ma identifica solo una piccola frazione dei deceduti — utile quando ogni allarme deve corrispondere a un caso critico. RIPPER è l'unico rule-list a produrre regole congiuntive (AND tra più condizioni): nonostante la maggiore espressività strutturale, ottiene il ROC-AUC più basso di tutti i modelli. Il vantaggio strutturale non si traduce in migliore capacità discriminativa su questo dataset.

Modello	Categoria	ROC-AUC	F1
SkopeRules	Rule-based	0.8960	0.1000
RandomForest	Ensemble	0.8960	0.7500

Tuning degli iperparametri. La selezione sul validation set ha mostrato che per BayesianRuleList la cardinalità ottimale è 1 (regole a condizione singola sono sufficienti su questo dataset), mentre per SkopeRules `max_depth=2` produce regole bi-condizionali ad alta precisione. Per gli ensemble, i valori ottimali tendono a configurazioni più semplici (meno stimatori, alberi poco profondi), coerente con la dimensione ridotta del dataset.

Precision vs Recall in ambito clinico. Il trade-off tra precisione e recall non è neutro in contesti medici. Alta recall minimizza i falsi negativi (morti non rilevate), che in clinica sono più pericolosi dei falsi positivi (falsi allarmi). Alta precisione garantisce invece che ogni segnalazione sia affidabile, preferibile quando si pianificano interventi invasivi. La scelta del modello dipende quindi dal contesto d'uso, e la trasparenza dei modelli rule-based è la condizione necessaria per fare questa scelta in modo consapevole.

Validazione qualitativa delle regole. Le feature più ricorrenti — `time` (follow-up), `serum_creatinine` ed `ejection_fraction` — sono coerenti con la letteratura clinica sull'insufficienza cardiaca: follow-up breve segnala una fase acuta critica, creatinina alta indica insufficienza renale, ejection fraction bassa riflette ridotta capacità di pompa. Il fatto che i modelli apprendano autonomamente queste relazioni costituisce una validazione qualitativa.

Ablazione della feature `time`. Rimuovendo `time` da RF e GRL (con ri-tuning sul validation set senza `time`), il ROC-AUC scende di circa 0.10 per entrambi i modelli. Senza `time` i modelli si affidano a `serum_creatinine` ed `ejection_fraction` — feature biochimiche disponibili alla prima valutazione, prima del follow-up — e rimangono utilizzabili in contesti di triage, anche se con discriminazione ridotta.

Limiti e sviluppi futuri. Con ≈ 60 campioni nel test set (circa 19 deceduti) ogni metrica è soggetta ad alta varianza: un solo paziente classificato diversamente sposta F1 di oltre 0.05. I risultati sono quindi indicativi e richiedono validazione su coorti esterne prima di qualsiasi applicazione clinica. Ulteriori sviluppi potrebbero includere la calibrazione delle probabilità predette e l'integrazione in un sistema di supporto decisionale con supervisione medica — contesto in cui la trasparenza dei

modelli rule-based resta il requisito imprescindibile.