

XAI Project

Heart Failure Clinical Records

Confronto tra metodi interpretabili basati su regole
e metodi non interpretabili basati su ensemble di alberi

Dataset: UCI Heart Failure Clinical Records (id=519)

Librerie: imodels · scikit-learn · xgboost

Capitolo 1

Introduzione

Contesto del problema, dataset e analisi esplorativa

Contesto e motivazione

Il problema

L'insufficienza cardiaca è una condizione clinica grave in cui il cuore non riesce a pompare sangue in modo sufficiente. Identificare i fattori di rischio associati al decesso è fondamentale per supportare le decisioni cliniche e migliorare la prognosi dei pazienti.

Obiettivo

Il progetto confronta due famiglie di modelli di machine learning per la predizione della mortalità: modelli interpretabili basati su regole (rule-based) e modelli non interpretabili basati su ensemble di alberi. L'obiettivo è valutare il trade-off tra performance predittiva e interpretabilità in un contesto clinico ad alta criticità.

Explainable AI in ambito clinico

In medicina, un modello non spiegabile — per quanto accurato — non è direttamente utilizzabile come strumento di supporto decisionale: il medico deve poter comprendere e validare le motivazioni di ogni predizione. I modelli intrinsecamente interpretabili soddisfano questo requisito senza richiedere metodi post-hoc aggiuntivi (es. SHAP, LIME), che possono introdurre approssimazioni e spiegazioni fuorvianti.

Struttura del report

Il Capitolo 1 descrive il dataset e l'analisi esplorativa. Il Capitolo 2 illustra i modelli utilizzati. Il Capitolo 3 presenta i risultati, il confronto delle performance e le conclusioni.

Il Dataset

Descrizione

Il dataset Heart Failure Clinical Records (UCI, id=519) raccoglie cartelle cliniche di 299 pazienti con insufficienza cardiaca seguiti in follow-up. La variabile target DEATH_EVENT indica se il paziente è deceduto durante il periodo di osservazione.

Campioni: 299 | Feature: 12 | Decessi: 96 (32.1%) | Sopravvissuti: 203 (67.9%)


Gestione delle feature: binarie vs continue

Le 12 feature si dividono in 5 binarie (anaemia, diabetes, high_blood_pressure, sex, smoking — valori 0/1) e 7 continue (age, creatinine_phosphokinase, ejection_fraction, platelets, serum_creatinine, serum_sodium, time). I modelli ensemble e la maggior parte dei rule-based le ricevono direttamente. RuleFit richiede standardizzazione (StandardScaler), mentre BayesianRuleList richiede feature esclusivamente binarie: le variabili continue vengono quindi discretizzate in bin tramite KBinsDiscretizer con one-hot encoding prima del fitting.


Feature	Tipo	Descrizione
age	continua	Età del paziente (anni)
anaemia	binaria	Presenza di anemia (0/1)
creatinine_phosphokinase	continua	Livello CPK nel sangue (mcg/L)
diabetes	binaria	Presenza di diabete (0/1)
ejection_fraction	continua	Percentuale di sangue pompata dal ventricolo sinistro (%)
high_blood_pressure	binaria	Presenza di ipertensione (0/1)
platelets	continua	Conta piastrinica (kiloplatelets/mL)
serum_creatinine	continua	Livello di creatinina serica (mg/dL)
serum_sodium	continua	Livello di sodio sierico (mEq/L)
sex	binaria	Sesso biologico (0=F, 1=M)
smoking	binaria	Fumatore (0/1)
time	continua	Durata del follow-up (giorni)

EDA — Distribuzioni per classe

Distribuzione feature continue per classe



EDA — Matrice di correlazione



Capitolo 2

Modelli

Approcci interpretabili basati su regole ed ensemble non interpretabili

Modelli Interpretabili Basati su Regole

I modelli basati su regole producono predizioni nella forma di liste di condizioni if-then direttamente leggibili. Ogni regola può essere validata da un esperto di dominio senza strumenti aggiuntivi.

RuleFit

Estrae regole da un ensemble di alberi, poi allena una regressione lineare penalizzata (Lasso) sui valori delle regole. Il coefficiente di ogni regola indica il suo peso nella predizione finale.

Richiede feature standardizzate.

GreedyRuleList

Costruisce una lista ordinata di regole if-then in modo greedy, massimizzando ad ogni passo la riduzione dell'impurità. La lista si legge dall'alto verso il basso: si applica la prima regola che si attiva sul campione.

BayesianRuleList (BRL)

Apprende una lista di regole tramite inferenza Bayesiana (MCMC). Richiede feature binarie: le variabili continue vengono discretizzate in bin (one-hot encoding) prima del fitting. Produce liste compatte e altamente leggibili.

FIGS — Fast Interpretable Greedy-Tree Sums

Il modello è una somma di piccoli alberi decisionali, ciascuno appreso in modo greedy sui residui del passo precedente. Combina interpretabilità strutturale con una capacità espressiva maggiore rispetto a un singolo albero.

SkopeRules

Genera regole ad alta precisione e recall tramite sub-campionamenti ripetuti di ensemble di alberi, poi de-duplica le regole simili. Ogni regola è corredata da statistiche di precisione, recall e support sul training set.

Modelli Ensemble Non Interpretabili

I modelli ensemble combinano centinaia di alberi decisionali per ottenere performance superiori, ma il processo decisionale risulta opaco (black box). Sono usati come baseline di riferimento per valutare il gap di performance rispetto ai modelli interpretabili.

Random Forest

Allena N alberi decisionali su sotto-campioni casuali del dataset (bagging) e su sottoinsiemi casuali delle feature (feature bagging). La predizione finale è la media delle probabilità dei singoli alberi. Riduce la varianza rispetto al singolo albero. Configurato con `class_weight='balanced'` per gestire lo sbilanciamento.

Gradient Boosting (sklearn)

Allena alberi sequenzialmente: ogni albero corregge gli errori del precedente minimizzando il gradiente della loss (boosting). Riduce il bias rispetto al bagging. Parametri: 200 stimatori, learning rate 0.05, profondità massima 4, subsample 0.8.

XGBoost

Implementazione ottimizzata del gradient boosting con regolarizzazione L1/L2, gestione nativa dei valori mancanti e parallelismo. Parametro `scale_pos_weight` impostato automaticamente per bilanciare le classi in base alla distribuzione del training set.

Preprocessing

I modelli ensemble non richiedono standardizzazione delle feature. Le variabili continue e binarie sono passate direttamente come array NumPy. Solo RuleFit utilizza feature standardizzate (StandardScaler); BRL utilizza feature discretizzate in bin binari (KBinsDiscretizer + one-hot encoding).


Capitolo 3

Risultati


Valutazione delle performance e confronto tra approcci

Metriche Comparative

Modello	Type	Accuracy	Precision	Recall	F1	ROC-AUC
RandomForest	Ensemble	0.8333	0.8	0.6316	0.7059	0.9012
SkopeRules	Rule-based	0.6833	0.0	0.0	0.0	0.8986
GreedyRuleList	Rule-based	0.8333	0.9091	0.5263	0.6667	0.8851
RuleFit	Rule-based	0.8167	0.8333	0.5263	0.6452	0.8825
XGBoost	Ensemble	0.8333	0.8	0.6316	0.7059	0.8511
GradientBoosting	Ensemble	0.8167	0.75	0.6316	0.6857	0.8472
BayesianRuleList	Rule-based	0.75	0.5714	0.8421	0.6809	0.8408
FIGS	Rule-based	0.75	0.6667	0.4211	0.5161	0.767



Curve ROC



Matrici di Confusione

RuleFit

Actual	Survived	39	2
	Deceased	9	10
	Predicted	Survived	Deceased

GreedyRuleList

Actual	Survived	40	1
	Deceased	9	10
	Predicted	Survived	Deceased

BayesianRuleList

Actual	Survived	29	12
	Deceased	3	16
	Predicted	Survived	Deceased

FIGS

Actual	Survived	37	4
	Deceased	11	8
	Predicted	Survived	Deceased

SkopeRules

Actual	Survived	41	0
	Deceased	19	0
	Predicted	Survived	Deceased

RandomForest

Actual	Survived	38	3
	Deceased	7	12
	Predicted	Survived	Deceased

GradientBoosting


Actual	Survived	37	4
	Deceased	7	12
	Predicted	Survived	Deceased

XGBoost


Actual	Survived	38	3
	Deceased	7	12
	Predicted	Survived	Deceased

Interpretabilità — Regole RuleFit


RuleFit — Regole pro DECESSO




RuleFit — Regole pro SOPRAVVIVENZA



Interpretabilità — Feature Importance RF



Cross-Validation 10-fold



Conclusioni

Trade-off interpretabilità vs performance

I modelli ensemble raggiungono generalmente performance superiori in termini di ROC-AUC rispetto ai modelli basati su regole. Tuttavia il divario non è sempre significativo, e i modelli interpretabili risultano competitivi su dataset di dimensioni ridotte come questo (299 campioni).

Rilevanza clinica delle regole

Le feature più ricorrenti nelle regole apprese — serum_creatinine, ejection_fraction e time — sono coerenti con la letteratura clinica sull'insufficienza cardiaca. Questo costituisce una forma di validazione qualitativa del modello.

Vantaggio dei modelli interpretabili

In contesti ad alta criticità come la medicina clinica, la possibilità di ispezionare esplicitamente le regole è fondamentale. I modelli intrinsecamente interpretabili soddisfano i requisiti di trasparenza senza richiedere metodi post-hoc, riducendo il rischio di spiegazioni fuorvianti.

Nota sul dataset

Con soli 299 campioni e un moderato sbilanciamento delle classi (~32% positivi), i risultati sul test set sono soggetti a varianza. La cross-validation a 10 fold fornisce una stima più robusta delle performance reali.

Migliori modelli per categoria:

Categoria	Modello	ROC-AUC	F1
Rule-based	SkopeRules	0.8986	0.0000
Ensemble	RandomForest	0.9012	0.7059